


GPT 2 Cheatsheet



		总体流程	
1	输入	Text	$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right)$ $PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}}\right)$
2		Tokenizer	
3		Positional Embedding	
4	自注意力机制 Self-Attention	$Q = W_q(X), K = W_k(X), V = W_v(X)$	$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$ $\text{Masked-Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T + M}{\sqrt{d_k}}\right)V$
5		$QK^T / \sqrt{d_k}$	
6		$\text{Softmax}(QK^T / \sqrt{d_k})$	
7		$A = \text{Attention}(Q, K, V)$	
8	后处理	$A + X$ (残差连接)	
9		$\text{LayerNorm}(A + X)$	
10		Feed Forward Network (FFN)	$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$
11		$FFN + \text{LayerNorm}(A + X)$	
12	输出	$\text{logits} = W_{\text{vocab}}(\text{output})$	$\text{Logits} = XW_{\text{vocab}} + b$
13		$\text{Softmax}(\text{logits}) \rightarrow$ 预测概率	
14		$\text{argmax}(\text{probabilities}) \rightarrow$ 预测 Token	

1. 超参数 Hyperparameters

超参数	作用	典型值
batch_size	一次训练的样本数	4, 8, 16
context_length	句子最大token长度	16, 512, 1024
d_model	Transformer 词向量维度	64, 768, 12288 (GPT-3)
num_heads	注意力头数	4, 8, 12, 96 (GPT-3)
num_layers	Transformer 堆叠层数	8, 12, 24, 96 (GPT-3)
head_size	每个注意力头的维度	d_model / num_heads
learning_rate	学习率	5e-4, 1e-03
dropout	Dropout 比例, 防止过拟合	0.1, 0.2, 0.3
vocab_size	词表大小	10K, 50K (GPT-3: 50257), 100K
max_iters	训练最大迭代次数	500, 2k, 20k, 50k

2. 数据预处理

变量	含义	形状
text	读取的文本内容	str
tokenized_text	令牌化后的文本	[N] [77919]
train_data	训练集	[N*90%] 0~70126
val_data	验证集	[N*10%] 70127~77918
x_batch	当前批次输入	[batch_size, context_length] [4, 16]
y_batch	目标输出 (右移一位的 x_batch)	[4, 16]
max_token_value	token ID 中的 最大值	100069

3. 嵌入层 & 位置编码

变量	含义	形状
token_embedding_lookup_table	词向量查找表	$[\text{max_token_value}+1, \text{d_model}]$ [100070, 64]
x_batch_embedding	将 x_batch 映射到词嵌入	$[\text{batch_size}, \text{context_length}, \text{d_model}]$ [4, 16, 64]
position_encoding_lookup_table	位置编码矩阵	[4, 16, 64]
input_embedding_x	词嵌入 + 位置编码	[4, 16, 64]

4. 计算Query, Key, Value

变量	含义	形状
query	等于 X	$[\text{batch_size}, \text{context_length}, \text{d_model}]$ [4, 16, 64]
key	等于 X	[4, 16, 64]
value	等于 X	[4, 16, 64]
W_q, W_k, W_v	线性变换矩阵	$[\text{d_model}, \text{d_model}]$ [64, 64]
Q, K, V	经过 W_q, W_k, W_v 投影后的 query, key, value	[4, 16, 64]
Q, K, V (拆分头)	变为 num_heads = 4 头	[4, 16, 4, 16]
Q, K, V (转置)	交换维度, 便于计算	[4, 4, 16, 16]

5. 计算Attention Scores

变量	含义	形状
attention_score	$QK^T / \sqrt{d_k}$	[4, 4, 16, 16]
attention_score(mask)	遮挡未来信息	[4, 4, 16, 16]
attention_score (Softmax)	归一化注意力	[4, 4, 16, 16]
A (加权求和)	attention_score @ v	[4, 4, 16, 16]
A (合并头)	A.transpose(1, 2).reshape()	[4, 16, 64]

6. Transformer Block (投影, 残差连接, 前馈网络)

变量	含义	形状
Wo	线性变换 $d_{\text{model}} \rightarrow d_{\text{model}}$	[64, 64]
output	Wo(A)	[4, 16, 64]
output + X	残差连接	[4, 16, 64]
LayerNorm	归一化	[4, 16, 64]
FeedForward	线性变换 $64 \rightarrow 256 \rightarrow 64$	[4, 16, 64]
output + output_layernorm	残差连接	[4, 16, 64]
LayerNorm	再次归一化	[4, 16, 64]

7. 计算最终预测

变量	含义	形状
logits	Linear(d_{model} , vocab_size)	[4, 16, vocab_size]
probabilities	Softmax(logits)	[4, 16, vocab_size]
predicted_index	argmax(probabilities)	[4, 16]